

TKOM - Python++

Dokumentacja

Michał Sobiech 318722

05.06.2024

1 Temat

- Temat nr 8: Język z wbudowanym typem słownika, którego zawartość można sortować. Możliwe są podstawowe operacje na słowniku (dodawanie, usuwanie, wyszukiwanie elementów wg klucza, sprawdzanie, czy dany klucz znajduje się w słowniku itd.), iterowanie po elementach oraz wykonywanie na słowniku zapytań w stylu LINQ. Metoda sortująca elementy słownika przyjmuje jako argument funkcję określającą kolejność elementów.
- Typowanie dynamiczne
- Język silnie typowany
- Język realizacji projektu: Python

2 Sposób uruchamiania

```
$ python++ main.ppp
```

3 Zakładana funkcjonalność

- Obsługiwane typy danych
 - Liczby
 - * Int
 - * Float
 - Wartość logiczna - bool
 - Ciąg znaków - string
 - Słownik - dict
 - * Dodawanie elementów

- * Odejmowanie elementów
- * Wyszukiwanie elementów po kluczu
- * Wyszukiwanie elementów po indeksie
- * Sprawdzanie obecności klucza w słowniku
- * Iterowanie po elementach
- * Sortowanie słownika przy użyciu funkcji określającej kolejność elementów
- * Operacje w stylu LINQ
- Lista - list
 - * Dodawanie i odejmowanie elementów
 - * Wyszukiwanie elementów po indeksie
- Para klucz-wartość - pair
 - * dostęp do klucza
 - * dostęp do wartości
- Obsługa komentarzy
- Możliwość tworzenia zmiennych, przypisywania im wartości i odczytywania ich
- Wszystko jest mutowalne
- Instrukcje warunkowe
 - if
 - elif
 - else
- Instrukcje pętli
 - for
 - while
- Możliwość definiowania i wywoływania własnych funkcji
- Przekazywanie argumentów do funkcji przez wartość
- Zmienne dostępne jedynie w swoim zakresie (brak rozwiązania w stylu pythonowego "global")
- Rekursywne wywołania funkcji
- Obsługa błędów przez interpreter
- Brak niejawnej konwersji
- Przeciążanie funkcji niedozwolone
- Przykrywanie zmiennych dozwolone

4 Struktura

4.1 Komponenty

- Źródło kodu
 - Leniwie czyta kolejne znaki kodu źródłowego
 - Klasa
 - * `CodeSource(src_file_path: str)` - ładuje znaki ze wskazanego pliku. Implementuje funkcje iteratora, więc znaki pobiera się wywołaniem `next()`.
- Analizator leksykalny
 - Przetwarza znaki na tokeny
 - Leniwie podbiera znaki od źródła kodu
 - Klasa
 - * `Lexer(code_source: CodeSource, error_handler: ErrorHandler)`
 - `get_next_token()` -> `Optional[Token]` - zwraca kolejny token. Jeśli lexer już wyczerpał znaki, to metoda zwraca `None`.
 - `get_current_token()` -> `Token` - zwraca ostatni ułożony token
 - `get_current_token_pos()` -> `tuple[int, int]` - zwraca pozycję obecnego tokenu w postaci krotki zawierającej kolejno rząd i kolumnę liczone od 0.
- Analizator składniowy
 - Generuje drzewo składniowe na podstawie tokenów
 - Klasa
 - * `Parser(lexer: Lexer, error_handler: ErrorHandler)`
 - `get_ast()` -> `Code` - zwraca drzewo składniowe
- Interpreter
 - Wykonuje instrukcje z drzewa składniowego
 - Klasa
 - * `Interpreter(ast: Code, output_stream: IOBase, error_handler: ErrorHandler)`
 - `interpret()` -> `None` - wykonuje instrukcje z AST.

4.2 Gramatyka

4.2.1 Symbole obsługiwane przez parser

```
code = { fun_definition | statement };
```

```
fun_definition = "def", id, "(", fun_params, ")", block;
```

```

fun_params      = [ id { ",", id } ];

statement       = assign_or_expr_or_incrdecr, ";"
                 | return, ";"
                 | cond_statement,
                 | for_loop
                 | while_loop;

id_or_fun_call  = id, [ "(", [ fun_call_args ], ")" ];

assign_or_expr_or_incrdecr = expression, [ '=', expression
                                     | ( "++" | "--" ) ];

cond_statement  = if_statement, { elif_statement }, [ else_statement ];
if_statement    = "if", expression, block;
elif_statement  = "elif", expression, block;
else_statement  = "else", block;
block           = "{", { statement }, "}";

fun_call_args   = expression, { ",", expression };

for_loop        = "for", id, "in", expression, block;

while_loop      = "while", expression, block;

return          = "return", [ expression ];

expression      = and_term, { "or", and_term };
and_term        = not_term, { "and", not_term };
not_term        = [ "not" ], comp_term;
comp_term       = add_or_sub_term, [ comp_operator, add_or_sub_term ];
add_or_sub_term = mul_or_div_term, { ("+" | "-"), mul_or_div_term };
mul_or_div_term = unary_minus_term, { ("*" | "/"), unary_minus_term };
unary_minus_term = [ "-" ], dot_term;
dot_term        = term, { ".", term };
nested_expression = "(", expression, ")";
term            = literal
                 | list
                 | dict_or_pair
                 | id_or_fun_call
                 | nested_expr
                 | linq_query;

linq_query      = "from", id, "in", expression, "where", expression,
                 [ "orderby", expression ],
                 "select", expression, { ",", expression };

```

```

dict_or_pair    = "{", ( "{"
                    | (expression, ("", expression
                    | ":", expression, [ dict_elems ] ), "}" ) );

dict_elems      = dict_element, { "", dict_element };
dict_element    = expression, ":", expression;

list            = "[", [ list_elems ], "];
list_elems      = expression, { "", expression };

```

4.2.2 Symbole obsługiwane przez lekser

```

comp_operator   = "<" | ">" | "<=" | ">=" | "==";

variable        = id, { ".", id };

id              = ( letter | "_" ) { alphanumeric | "_" };

literal         = string | int | float | bool | none;

none            = "None";

bool            = "True" | "False";

string          = "'", { ascii_char }, "'";

float           = int, ".", positive_int;
int             = "0" | nonzero_digit, { digit };

alphanumeric    = letter | digit;
letter          = wszystkie małe i duże litery
digit           = "0" | nonzero_digit;
nonzero_digit   = "1" | "2" | "3" | "4" | "5" | "6" | "7" | "8" | "9";
ascii_char      = dowolny znak ascii

```

4.3 Priorytety operatorów

Asocjacyjność operatorów. Im wyżej w tabeli, tym wyższy priorytet

Operator	Asocjacyjność
() .	-
not - (unarny)	-
* /	Lewostronna
+ - (odejmowanie)	Lewostronna
> >= < <= ==	-
and	Lewostronna
or	Lewostronna

Operatory "++" i "--" są poza hierarchią.

4.4 Rodzaje tokenów

Tokeny to obiekty posiadające 3 pola:

- Rodzaj
- Wartość (pusta dla niektórych rodzajów, np. Plus)
- Pozycja w kodzie

Pogrupowane rodzaje:

- Literały wbudowanych typów
 - IntLiteral
 - FloatLiteral
 - StringLiteral
- Operatory do obliczeń
 - Plus
 - PlusPlus
 - Minus
 - MinusMinus

- Multiply
 - Divide
- Operatory do porównywania
 - Less
 - LessEquals
 - Greater
 - GreaterEquals
 - EqualsEquals
- Operatory logiczne
 - Or
 - And
 - Not
- Słowa-klucze
 - Def
 - Return
 - For
 - In
 - If
 - Elif
 - Else
 - From
 - Where
 - Select
 - OrderBy
 - True
 - False
 - None
- Nawiasy
 - ParenthesesLeft
 - ParenthesesRight
 - BracketsLeft
 - BracketsRight
 - BracesLeft
 - BracesRight

- Pozostałe
 - Identifier
 - Comment
 - Comma
 - Colon
 - Dot
 - Whitespace

5 Testowanie

Będą 2 rodzaje testów:

- Jednostkowe, przeprowadzane dla każdego modułu oddzielnie
 - Testy kodu źródła
 - Testy leksera
 - Testy parsera
 - Testy interpretera
- Integracyjne

6 Przykładowy kod

6.1 Definiowanie zmiennych

```
bool_var = True;
int_var = 1;
float_var = 0.1;
str_var = 'sample text';
dict_var = {'a': 1, 'b': 2};
list_var = [1, 2, 3];
pair_var = {'a', 1};
```

6.2 Definiowanie i wywoływanie funkcji

```
def increment(number) {
    return number + 1;
}
```

```
a = increment(1);
```


6.3 Globalne funkcje wbudowane

```
print(1);          # prints 1
bool(1);           # True
int('123') ;       # 123
float('123');       # 123.0
string(123);        # '123'
```

6.4 Komentarze

```
# This is a comment
```

6.5 Operatory

```
a + b;
a - b;
a * b;
a / b;
(a);
a.b();
not a;
-a;
a > b;
a >= b;
a < b;
a <= b;
a == b;
a and b;
a or b;
```

6.6 Operacje na stringach

```
a = 'sample';

a + 'text'      # 'sampletext'
```

6.7 Operacje na listach

```
list = [1, 2, 3];

list.length();    # 3

for e in list {
    print(e);
}
# 1
```

```
# 2
# 3

list.append(4);      # list = [1, 2, 3, 4]
list.pop();          # list = [1, 2, 3]
list.at(0);          # 1
```

6.8 Operacje na słownikach

```
dict = {
    'a': 1,
    'b': 2,
    'c': 3
};
dict.append({'d': 4}); # dict = {'a': 1, 'b': 2, 'c': 3, 'd': 4}

dict.by_key('c');      # 3
dict.by_index(1);      # {'a': 1}
dict.pop();            # dict = {'a': 1, 'b': 2, 'c': 3}
dict.length()          # 3
dict.has_key('a')      # True

# Sortowanie
dict = {'d': 4, 'a': 1, 'c': 3, 'b': 2};
def sort_func(tuple_a, tuple_b) {
    return tuple_a.value() > tuple_b.value();
}
dict.sort(sort_func);  # dict = {'a': 1, 'b': 2, 'c': 3, 'd': 4}
```

6.9 Operacje na krotkach

```
a = {'a', 1};

a.key();    # 'a'
a.value()   # 1
```

6.10 Operacje w stylu LINQ

```
dict = {
    'd': 4,
    'a': 1,
    'b': 2,
    'c': 3
};

def sorting_fun(a, b) {
```

```

    return a.value() < b.value();
}

result = from tuple in dict
    where tuple.value() > 2
    orderby sorting_fun
    select tuple.key(), tuple.value();
# [['c', 3], ['d', 4]]

```

7 Obsługa błędów

7.1 Błędy leksera - TokenError

Format błędu:

[Rodzaj błędu], line [numer linii], column [numer kolumny]: [Opis błędu]

- Kody
 1. STR_EOF_INSIDE - znak końca pliku pojawił się w trakcie definicji stringa
 2. CHAR_AFTER_STR_END - Znak pojawił się zaraz po definicji stringa
 3. FLOAT_INVALID_CHAR - Niewłaściwy znak pojawił się w środku definicji floata
 4. INT_INVALID_CHAR - Niewłaściwy znak pojawił się w trakcie definicji liczby całkowitej
 5. INT_DIGIT_AFTER_ZERO - Po zerze pojawiła się liczba
- Przykłady
 - 1a = 1;

```

Lexer error at line 1, column 2: Invalid char inside a number (int/float)
definition.

```

7.2 Błędy parsera - SyntaxError

- Format błędu:

[Rodzaj błędu], line [numer linii], column [numer kolumny]: [Opis błędu]
- Kody
 1. NEITHER_FUN_DEF_NOR_STATEMENT
 2. FUN_INVALID_NAME

3. FUN_NO_LEFT_PARENTHESES
4. FUN_NO_RIGHT_PARENTHESES
5. FUN_DEF_INVALID_PARAM
6. FUN_DEF_INVALID_BODY
7. FUN_CALL_INVALID_ARG
8. BLOCK_NO_RIGHT_BRACES
9. IF_INVALID_CONDITION
10. IF_INVALID_BODY
11. ELIF_INVALID_CONDITION
12. ELIF_INVALID_BODY
13. ELSE_INVALID_BODY
14. ASSIGN_INVALID_RIGHT_SIDE
15. NO_SEMICOLON
16. OR_TERM_INVALID_RIGHT_SIDE
17. AND_TERM_INVALID_RIGHT_SIDE
18. NOT_TERM_INVALID_RIGHT_SIDE
19. COMP_TERM_INVALID_RIGHT_SIDE
20. ADD_OR_SUB_TERM_INVALID_RIGHT_SIDE
21. MUL_OR_DIV_TERM_INVALID_RIGHT_SIDE
22. MINUS_TERM_INVALID_RIGHT_SIDE
23. DOT_TERM_INVALID_TERM
24. LINQ_INVALID_ITERATOR_VAR
25. LINQ_NO_IN
26. LINQ_INVALID_SEQUENCE
27. LINQ_NO_WHERE
28. LINQ_INVALID_CONDITION
29. LINQ_NO_ORDERBY_FUN
30. LINQ_NO_SELECT
31. LINQ_INVALID_SELECTED_VALUES
32. LINQ_SELECTED_VALUES_END_WITH_COMMA
33. FOR_LOOP_INVALID_ITERATOR_VAR
34. FOR_LOOP_NO_IN
35. FOR_LOOP_INVALID_SEQUENCE
36. FOR_LOOP_INVALID_BODY
37. WHILE_LOOP_INVALID_CONDITION
38. WHILE_LOOP_INVALID_BODY

- 39. DICT_NO_RIGHT_BRACES
- 40. DICT_ELEM_INVALID_VALUE
- 41. DICT_ELEM_NO_COLON
- 42. INVALID_DICT_ELEM
- 43. PAIR_INVALID_VALUE
- 44. PAIR_NO_RIGHT_BRACES
- 45. LIST_INVALID_ELEMENT
- 46. LIST_NO_RIGHT_BRACKETS
- 47. NESTED_EXPR_INVALID_EXPR
- 48. NESTED_EXPR_NO_RIGHT_PARENTHESES

- Przykłady

- `print(a)`

- Syntax error at line 1, column 9: Expected a semicolon.

- `def a() {};`

- Syntax error at line 1, column 11: Neither a function definition nor a statement.

7.3 Błędy interpretera - InterpreterError

- Format błędu:

[Rodzaj błędu], line [numer linii], column [numer kolumny]: [Opis błędu]
Context stack: [...]

- Kody

- 1. STACK_OVERFLOW
- 2. FUNCTION_ALREADY_EXISTS
- 3. NO_SUCH_FUNCTION
- 4. INVALID_ARG_COUNT
- 5. INVALID_TYPE
- 6. INVALID_VALUE
- 7. NAME_TAKEN_BY_FUNCTION
- 8. NAME_TAKEN_BY_VAR
- 9. NO_SUCH_OBJECT
- 10. NO_SUCH_RVALUE

- 11. ARG_INVALID_TYPE
- 12. DIVISION_BY_ZERO
- 13. DICT_KEY_EXISTS
- 14. NO_SUCH_KEY_IN_DICT
- 15. DICT_IS_EMPTY
- 16. LIST_IS_EMPTY
- 17. INVALID_INDEX
- 18. UNITERABLE_OBJECT
- 19. NO_SUCH_VARIABLE

• Przykłady

- print(a);

InterpreterError at line 1, column 7: This variable/function does not exist.
Call stack:
print at line 1

- int('aaa');

InterpreterError at line 1, column 5: Invalid value(s).
Call stack:
int at line 1

- for element in 1 {
 print(e);
}

InterpreterError at line 1, column 16: Cannot iterate over this object.
Call stack:
(Empty)